Klasifikacija namene i pokrivenosti zemljišta na satelitskim snimcima primenom dubokih neuronskih mreža

Miloš Milanović, Bojan Živanić

Softversko inženjerstvo i informacione tehnologije, Univerzitet u Novom Sadu, Fakultet tehničkih nauka

milanovic.r25.2025@uns.ac.rs, zivanic.r222.2025@uns.ac.rs

Sažetak—Automatska klasifikacija namene i pokrivenosti zemljišta (engl. *land use / land cover*, LULC) iz satelitskih snimaka od suštinskog je značaja za savremeno upravljanje resursima, prostorno planiranje i praćenje klimatskih promena. U ovom radu se porede tri pristupa za 10-klasnu LULC klasifikaciju na skupu podataka EuroSAT [1]: prilagođena konvoluciona neuronska mreža (*baseline* CNN) trenirana od nule i dva modela zasnovana na transferu znanja — EfficientNetB0 [2] i ResNet50 [3] — podvrgnuta dvostepenom procesu finog podešavanja (engl. *fine-tuning*). Eksperimenti su sprovedeni po strogo simetričnom protokolu: identična stratifikovana podela (*seed*: 42), isto pravilo selekcije zasnovano isključivo na validacionom skupu i iste metrike primenjene su na sve tri familije modela. ResNet50 dostiže test tačnost od 97,88% i makro F1 skor od 97,85% za svega 14 epoha ukupnog treninga. EfficientNetB0 postiže 97,43% i 97,36% za 33 epohe. *Baseline* CNN ostvaruje 96,20% tačnosti i 96,09% makro F1 za 50 epoha. Ablaciona studija potvrđuje kritičnu ulogu dvostepenog finog podešavanja i augmentacije podataka za sve arhitekture.

Ključne reči—*transfer learning*; EuroSAT; EfficientNetB0; ResNet50; LULC; konvolucione neuronske mreže; satelitska klasifikacija.

I. UVOD I MOTIVACIJA

Klasifikacija namene i pokrivenosti zemljišta (LULC) na osnovu satelitskih snimaka jedan je od ključnih zadataka savremene daljinske detekcije. Tačna i pravovremena LULC analiza osnova je za donošenje odluka u oblastima od globalnog značaja: urbanog planiranja i praćenja širenja izgrađenih površina, precizne poljoprivrede i praćenja zdravlja useva, upravljanja šumskim ekosistemima i biodiverzitetom, te modeliranja klimatskih promena i ciklusa ugljenika [1], [4]. U kontekstu ubrzane urbanizacije i klimatskih promena, automatizovana LULC klasifikacija postaje neophodan alat za skalabilni, vremenski efikasan monitoring koji nije moguće ostvariti ručnom analizom.

Sentinel-2 misija Evropske svemirske agencije (ESA) obezbeđuje besplatne multispektralne snimke visokog prostornog razlučivanja (10–60 m po pikselu, u zavisnosti od spektralnog kanala) sa vremenskim intervalom ponovnog snimanja od samo pet dana za istu lokaciju. Ova misija svakodnevno generiše nekoliko terabajta sirovih satelitskih podataka koji pokrivaju gotovo celokupnu površinu Zemljinog kopna. Ručno tumačenje i klasifikacija ovakve količine snimaka praktično su neizvodivi u operativnoj skali — automatizovana obrada sposobna da u realnom vremenu klasifikuje stotine hiljada slikovnih isečaka postaje neophodnost.

Tradicionalni pristupi mašinskog učenja — metoda potpornih vektora (engl. *Support Vector Machine*, SVM) i slučajne šume (engl. *Random Forest*, RF) — dugo su bili standard u daljinskoj detekciji. Navedeni metodi zahtevaju ručno projektovanje karakteristika (engl. *feature engineering*), što ih čini vremenski zahtevnim i teško prenosivim između različitih scena i tipova senzora. Pored toga, podložni su greškama pri klasifikaciji vizuelno ili spektralno sličnih klasa (npr. godišnji i višegodišnji usevi, reke i autoputevi), jer ne mogu automatski naučiti hijerarhijske prostorno-spektralne reprezentacije.

Konvolucione neuronske mreže (CNN) revolucionisale su računarsku viziju [5] i dokazale svoju efikasnost i u daljinskoj detekciji — automatski se uče hijerarhijske reprezentacije, od nisko-nivonih karakteristika (ivice, boje, teksture) do visoko-nivonih semantičkih obrazaca (oblici objekata, prostorni raspored), direktno iz sirovih piksela. Transfer znanja (engl. *transfer learning*) [6] — prilagođavanje modela unapred treniranog na velikom skupu podataka (standardno ImageNet) za novi ciljni zadatak — dodatno unapređuje ovaj pristup: modeli zasnovani na transferu znanja konvergiraju brže, zahtevaju manje označenih uzoraka i tipično postižu veću tačnost u poređenju sa modelima treniranim od nule [7].

EfficientNetB0 [2] i ResNet50 [3] danas su industrijski standardi za klasifikacione zadatke sa snimcima, zahvaljujući izuzetnom odnosu performansi i računske efikasnosti. Međutim, u literaturi nema dovoljno sistematičnih studija koje upoređuju ove arhitekture pod strogo simetričnim eksperimentalnim protokolom na skupu EuroSAT. Cilj ovog rada je popunjavanje navedenog istraživačkog jaza — procena da li transfer znanja sa modernim unapred treniranim CNN osnovama (engl. *backbone*) poboljšava performanse u poređenju sa prilagođenim *baseline* CNN, pod identičnim pravilima podele, selekcije i evaluacije.

Istraživačka pitanja ovog rada su:

- Da li modeli zasnovani na transferu znanja nadmašuju *baseline* CNN na EuroSAT skupu pod identičnim pravilima podele i selekcije modela?
- Koliko dvostepeno fino podešavanje (zamrznuti → odmrznuti *backbone*) doprinosi u poređenju sa konfiguracijom u kojoj je *backbone* trajno zamrznut?
- Kakav je uticaj augmentacije podataka i stope učenja na konačne performanse svake familije modela?

Konkretni doprinosi rada su: (1) kvantitativno poređenje referentnog modela i modela zasnovanih na transferu znanja pod identičnim evaluacionim protokolom (isti manifest podele podataka, ista pravila selekcije, iste metrike); (2) ablaciona studija uticaja augmentacije i stope učenja za svaku arhitekturu; (3) analiza razlike između validacionih i test performansi kao procena generalizacije; (4) identifikacija konzistentno teških klasa i analiza uzroka spektralnih konfuzija kroz sve tri familije modela.

II. PREGLED RELEVANTNE LITERATURE

Helber i drugi [1] uveli su skup podataka EuroSAT zasnovan na Sentinel-2 multispektralnim snimcima i kreirali sveobuhvatan referentni okvir za LULC klasifikaciju sa 10 klasa. U originalnom radu, ResNet-50 model koji je fino podešen na RGB verziji skupa EuroSAT postigao je tačnost iznad 98,57%, dok je RGB+IR verzija dostigla 98,71%. Taj rad postavio je referentnu tačku za naknadne studije na navedenom skupu i snažno motivisao primenu transfera znanja u satelitskoj klasifikaciji. Napomenu je da su u originalnom radu Helber-a i saradnika korišćeni drugačija podela podataka i protokol selekcije, što otežava direktno poređenje apsolutnih rezultata.

Tan i Le [2] predložili su familiju EfficientNet zasnovanu na principu složenog skaliranja (engl. *compound scaling*): umesto skaliranja samo jedne dimenzije mreže (dubina, širina ili rezolucija ulaza), uveden je koeficijent koji skalira sve tri dimenzije simultano prema unapred definisanoj formuli. EfficientNetB0, bazni model te familije sa ~5,3 miliona parametara, postiže konkurentne tačnosti uz znatno manji računski otisak od ResNet50, što ga čini posebno pogodnim za skupove podataka srednje veličine poput EuroSAT-a.

He i drugi [3] uveli su rezidualne veze (engl. *skip connections*) u arhitekturu ResNet, rešavajući problem nestajućeg gradijenta (engl. *vanishing gradient*) koji je ograničavao uspešan trening mreža sa više od ~20 slojeva. Rezidualni blokovi propuštaju signal direktno iz ranijeg sloja u kasniji, zaobilazeći niz nelinearnih transformacija, čime se gradijent efektivno prenosi sve do prvih slojeva tokom unazadne propagacije greške (engl. *backpropagation*). ResNet-50, sa 50 slojeva i ~23,5 miliona parametara, kombinuje dubinu sa efikasnim tokom gradijenta i robusna je arhitektura za ekstrakciju bogatih hijerarhijskih reprezentacija iz satelitskih snimaka.

Zhang i drugi [4] pregledali su metode dubokog učenja u daljinskoj detekciji, naglašavajući augmentaciju kao ključnu komponentu regularizacije pri finom podešavanju, kao i važnost transfera znanja za smanjenje potrebe za velikim označenim skupovima podataka u daljinskim primenama.

Revoluciju dubokog učenja u računarskoj viziji pokrenuli su Krizhevsky i drugi [5] demonstrirajući da duboke CNN arhitekture trenirane na skupu ImageNet (1,2 miliona slika, 1.000 klasa) znatno nadmašuju metode zasnovane na ručno projektovanim karakteristikama. Navedeni rezultat postavio je temelje paradigme transfera znanja: osnove mreže (engl. *backbone*) prethodno trenirane na skupu ImageNet mogu se prilagoditi za raznolike ciljne zadatke uz znatno manji računski trošak, čak i kada ciljni domen (npr. satelitski snimci) znatno odstupa od izvornog domena (prirodne fotografije).

Pan i Yang [6] dali su sveobuhvatan pregled metoda prilagođavanja znanja između domenova. Ključni zaključak tog rada jeste da fino podešavanje konzistentno prevazilazi trening od nule kada ciljni skup ima dovoljan broj označenih uzoraka — što je slučaj sa skupom EuroSAT (~27.000 slika). Nogueira i drugi [7] sistematično su potvrdili navedeni nalaz specifično za daljinsku detekciju: fino podešavanje unapred trenirane mreže konzistentno nadmašuje trening od nule, ukazujući na robusnost nisko-nivonih karakteristika naučenih na skupu ImageNet koje su prenosive i na satelitske snimke.

Za razliku od prethodnih radova koji često koriste različite protokole podele podataka ili pravila selekcije modela, u ovom radu uveden je strogo simetričan eksperimentalni dizajn — identičan manifest podele, isto pravilo selekcije i iste metrike izveštavanja za sve tri familije modela — čime se obezbeđuju fer i reproduktibilno poređenje.

III. METODOLOGIJA I IMPLEMENTACIJA

A. Skup podataka

EuroSAT [1] jeste referentni skup podataka za LULC klasifikaciju izgrađen na osnovu RGB isečaka Sentinel-2 satelitskih snimaka (ESA). Skup sadrži 27.000 georeferenciranih slika fiksne rezolucije 64×64 piksela, ravnomerno raspoređenih u 10 klasa namene i pokrivenosti zemljišta (~2.700 slika po klasi). Ravnomerna raspodela čini tačnost pouzdanom primarnom metrikom bez potrebe za uzorkovanjem s vagom.

Klase obuhvataju: godišnje useve (*AnnualCrop*), šumu (*Forest*), zeljasty vegetaciju (*HerbaceousVegetation*), autoput (*Highway*), industrijsku zonu (*Industrial*), pašnjak (*Pasture*), višegodišnje useve (*PermanentCrop*), stambenu zonu (*Residential*), reku (*River*) i more ili jezero (*SeaLake*). Klase su validirane na osnovu georeferenciranih oznaka iz baze CORINE Land Cover — nije bila potrebna dodatna ručna anotacija.

B. Priprema podataka

Skup podataka podeljen je stratifikovano po klasama u odnosu 70% / 15% / 15% za trening, validacioni i test skup, uz fiksirani *seed* (vrednost 42). Stratifikovana podela garantuje da svaki podskup sadrži proporcionalni udeo uzoraka iz svake od 10 klasa, čuvajući uravnoteženost originalnog skupa i omogućavajući pouzdano poređenje metrika između modela. Artefakti podele sačuvani su kao JSON manifesti i ponovo iskorišćeni bez izmena za sve tri familije modela, obezbeđujući potpunu reproduktibilnost i isključujući razlike u performansama usled varijacija u podeli.

Za augmentaciju podataka tokom treninga primenjeni su nasumični horizontalni i vertikalni preokret slike. Augmentacija se primenjuje isključivo na trening skup — validacioni i test skup obrađuju se bez augmentacije. Uticaj augmentacije sistematično je ispitivan kroz ablacionu studiju za svaku familiju modela pokretanjem varijante bez augmentacije, uz sve ostale hiperparametare nepromenjene.

C. Arhitekture modela

Referentni model (Baseline CNN): Prilagođena konvoluciona mreža trenirana od nule, koja služi kao referentna tačka za kvantifikaciju dobitka od transfera znanja. Arhitektura se sastoji od uzastopnih blokova: konvolucioni sloj (jezgro 3×3) → grupna normalizacija (engl. *batch normalization*) → ReLU aktivacija → sažimajući sloj (engl. *max pooling*). Na vrhu mreže nalaze se globalni prosečni sažimajući sloj (engl. *global average pooling*) i linearni klasifikacijski sloj za 10 klasa.

EfficientNetB0: Inicijalizovan ImageNet težinama (~5,3 miliona parametara ukupno). Projektovan principom složenog skaliranja [2] kojim se sve tri dimenzije (dubina, širina, rezolucija ulaza) skaliraju uniformno definisanim koeficijentom, što obezbeđuje optimalan odnos tačnosti i efikasnosti za dati računarski budžet. Originalna izlazna glava zamenjena je linearnim klasifikacijskim slojem za 10 klasa

skupa EuroSAT. Odabran je zbog povoljnog odnosa tačnosti i broja parametara za skupove podataka srednje veličine.

ResNet50: Inicijalizovan ImageNet težinama (~23,5 miliona parametara ukupno). Rezidualne veze [3] rešavaju problem nestajućeg gradijenta koji nastaje pri treniranju duboke mreže: signal se propagira direktno iz ranijeg sloja u kasniji, zaobilazeći niz nelinearnih transformacija. Na ovaj način omogućen je efikasan trening mreže sa 50 slojeva bez degradacije performansi. Klasifikacijska glava zamenjena je linearnim slojem za 10 klasa. Odabran je kao komplementarna dublja arhitektura koja drugačije ekstrahuje prostorne karakteristike u poređenju sa EfficientNetB0.

D. Protokol treninga

Oba modela zasnovana na transferu znanja trenirana su dvostepeno radi stabilne inicijalizacije klasifikatora pre odmrzavanja osnove mreže:

Faza 1 (zamrznuta osnova mreže): Svi parametri osnove mreže su zamrznuti, a treniraju se isključivo parametri novog klasifikacijskog sloja. Stopa učenja je 0,001; augmentacija obuhvata horizontalni i vertikalni preokret slike. Ovaj korak brzo inicijalizuje klasifikator koristeći reprezentacije naučene na skupu ImageNet, pre nego što se stopa učenja snizi za fino podešavanje celog modela.

Faza 2 (odmrznuto fino podešavanje): Svi parametri mreže, uključujući osnovu, podvrgavaju se treningu sa niskom stopom učenja od 0,0001, uz nastavak iz sačuvane kontrolne tačke (engl. *checkpoint*) Faze 1. Augmentacija je zadržana. Rano zaustavljanje treninga (engl. *early stopping*) primenjeno je kako bi se sprečilo preprilagođavanje (engl. *overfitting*): trening se zaustavlja ako se validacioni makro F1 skor ne poboljšava tokom unapred definisanog broja uzastopnih epoha strpljenja.

Za referentni CNN primenjen je jednostepeni trening od nule sa stopom učenja 0,0005, augmentacijom i fiksiranim brojem od 50 epoha. Selekcija modela vrši se isključivo na osnovu validacionog makro F1 skora. Pravilo zaštite od curenja informacija: test skup ne koristi se ni u jednom koraku selekcije niti tokom praćenja performansi. Finalna evaluacija vrši se jednom, na test skupu, samo za selektovani model svake familije.

E. Metrike evaluacije

Evaluacija obuhvata: tačnost (engl. *accuracy*) kao primarnu metriku — validnu zbog uravnoteženog skupa; makro F1 skor (engl. *macro F1 score*) koji ravnomerno vrednuje svih 10 klasa bez obzira na veličinu; preciznost i odziv po klasi za identifikaciju klasa koje su modelima najteže; i matricu konfuzije za vizualizaciju sistematskih grešaka između parova klasa.

IV. REZULTATI I DISKUSIJA

A. Ablaciona studija – Referentni model (Baseline CNN)

Tabela I prikazuje rezultate ablacione studije za referentni model. Polazna konfiguracija bez augmentacije postiže test makro F1 od 90,89%. Primenom augmentacije (horizontalni i vertikalni preokret slike) ostvaruje se poboljšanje od +3,73 procentna poena (pp). Naknadnim smanjenjem stope učenja sa 0,001 na 0,0005 dobija se daljih +1,47 pp, čime selektovani model (*baseline_flips_low_lr*) postiže test tačnost 96,20% i makro F1 96,09%. Navedeni rezultati ukazuju na visoku osetljivost referentnog CNN na oba hiperparametra — augmentaciju i stopu učenja.

TABELA I

Ablaciona studija za referentni model (seed 42).

Varijanta	Aug.	Stopa uč.	Val F1	Test Acc	Test F1
ref_none	ne	0.001	0.9154	91.23%	90.89%
flips	da	0.001	0.9518	94.79%	94.62%
flips_low_lr *	da	0.0005	0.9598	96.20%	96.09%

*Aug. = augmentacija; Val F1 = validacioni makro F1; * Selektovani model.*

B. Ablaciona studija – Modeli zasnovani na transferu znanja

Tabela II prikazuje ablacione rezultate za oba modela zasnovana na transferu znanja. Za obe arhitekture, fino podešavanje u Fazi 2 donosi konzistentno poboljšanje: EfficientNetB0 ostvaruje +5,05 pp makro F1 u Fazi 2 naspram Faze 1, dok ResNet50 ostvaruje +5,26 pp. Uklanjanje augmentacije degradira makro F1 za 0,77 pp (EfficientNetB0) i 1,49 pp (ResNet50) u odnosu na referentnu konfiguraciju Faze 2, čime se potvrđuje kritična uloga augmentacije čak i za modele zasnovane na transferu znanja. Smanjenje stope učenja sa 0,0001 na 0,00005 donosi blago pogoršanje validacionog F1 za oba modela, što sugeriše da je stopa 0,0001 bliža optimalnoj za obe arhitekture na skupu EuroSAT.

TABELA II

Ablaciona studija za modele zasnovane na transferu znanja (seed 42).

Model	Varijanta	Faza	Aug.	Val F1	Test Acc	F1
EffNet-B0	stage1_ref	F1	da	0.9208	92.62%	92.31%
EffNet-B0	stage2_ref *	F2	da	0.9789	97.43%	97.36%
EffNet-B0	stage2_low_lr	F2	da	0.9755	97.14%	97.03%
EffNet-B0	stage2_no_aug	F2	ne	0.9659	96.69%	96.59%
ResNet50	stage1_ref	F1	da	0.9291	92.79%	92.59%
ResNet50	stage2_ref *	F2	da	0.9784	97.88%	97.85%
ResNet50	stage2_low_lr	F2	da	0.9782	97.95%	97.91%
ResNet50	stage2_no_aug	F2	ne	0.9672	96.47%	96.36%

*F = Faza; Aug. = augmentacija; Val F1 = validacioni makro F1; F1 = test makro F1; * Selektovani modeli (odabrani po validacionom F1).*

C. Trostrano poređenje selektovanih modela

Tabela III prikazuje finalno poređenje tri selektovana modela na test skupu. Oba modela zasnovana na transferu znanja jasno nadmašuju referentni CNN: EfficientNetB0 za +1,23 pp u tačnosti i +1,27 pp u makro F1, a ResNet50 za +1,68 pp i +1,76 pp. ResNet50 dostiže najvišu test tačnost (97,88%) i makro F1 (97,85%), postavljajući se kao dominantan model u ovom skupu eksperimenata. Razlika između ResNet50 i EfficientNetB0 iznosi 0,44 pp u tačnosti i 0,49 pp u makro F1 — relativno mala razlika uzimajući u obzir da EfficientNetB0 ima 4,4 puta manji broj parametara.

TABELA III

Poređenje selektovanih modela na test skupu.

Familija modela	Test Acc	Makro F1	Epohe	Vreme (min)
Referentni CNN	96.20%	96.09%	50	≈97.9
EfficientNetB0	97.43%	97.36%	33	≈82.4
ResNet50	97.88%	97.85%	14	≈58.7

Epohe = ukupno (Faza 1 + Faza 2 za modele zasnovane na transferu). Vreme = ukupno vreme izvršavanja.

D. Analiza konvergencije i efikasnosti

Analiza brzine konvergencije otkriva jednu od najznačajnijih praktičnih prednosti transfera znanja. ResNet50 konvergira za svega 14 epoha ukupnog treninga (5 u Fazi 1 + 9 u Fazi 2), u poređenju sa 33 epohe za EfficientNetB0 (9+24) i 50 epoha za referentni CNN. Navedeni rezultat direktno odražava efikasnost prenosa znanja: osnove mreže unapred trenirane na skupu ImageNet već poseduju bogate reprezentacije vizuelnih karakteristika (ivice, teksture, oblici) delimično prenosive na satelitske snimke, čime se drastično smanjuje broj potrebnih iteracija za konvergenciju klasifikatora.

Ukupno vreme izvršavanja ResNet50 (≈58,7 min) kraće je za ≈39 minuta od referentnog CNN (≈97,9 min) i za ≈23 minuta od EfficientNetB0 (≈82,4 min). Kombinacija superiornih finalnih performansi i znatno kraćeg ukupnog vremena treninga čini ResNet50 najefikasnijim izborom u ovom skupu eksperimenata. Analiza stabilnosti generalizacije — razlika između validacionog i test makro F1 za selektovane modele — iznosi: +0,001 pp za referentni CNN; −0,005 pp za EfficientNetB0; i +0,0002 pp za ResNet50. ResNet50 pokazuje najjaču stabilnost, dok EfficientNetB0 beleži blagi pad od 0,5 pp koji ostaje u granicama normalnih varijacija.

E. Analiza grešaka po klasama

Analiza preciznosti i odziva po klasi, konzistentna kroz sve tri arhitekture, otkriva jasne obrasce snage i slabosti koji su vezani za inherentne karakteristike klasa, a ne za specifičnu arhitekturu.

Konzistentno jake klase: *Forest*, *Industrial* i *Residential*. Šume ispoljavaju karakteristično visok odraz u bliskom infracrvenom (NIR) delu spektra i uniformnu teksturnu strukturu, industrijske zone imaju distinktivne spektralne potpise betona, metala i asfalta sa karakterističnim geometrijskim oblicima, dok se stambene zone odlikuju pravilnim prostornim rasporedom krovova, vrtova i saobraćajnica. Navedene karakteristike su dovoljno jedinstvene da čak i referentni CNN postiže visok odziv za te klase.

Konzistentno teške klase: *PermanentCrop*, *River* i *Highway*. Višegodišnji usevi (*PermanentCrop*) i godišnji usevi (*AnnualCrop*) dele slične spektralne potpise tokom fenoloških faza aktivnog rasta: zelena vegetacija dominira scenom, a NIR odraz je sličan za oba tipa. Distinkcija između te dve klase zahteva temporalne serije snimaka ili analizu višespektralnih indeksa vegetacije (npr. NDVI tokom zimske dormancije), što prevazilazi mogućnosti RGB analize jednog isečka dimenzija 64×64. Reke (*River*) i autoputevi (*Highway*) dele linearnu prostornu strukturu na navedenoj rezoluciji: oba tipa pojavljuju se kao uske linearne strukture okružene kontrastnim pikselima. Kritična razlika — odsjaj vodene površine i zelena vegetacija duž rečnih obala nasuprot sivog asfalta i pratećih objekata duž autoputeva — može biti teško uočljiva bez višespektralnih informacija.

Oba modela zasnovana na transferu znanja konzistentno prevazilaze referentni CNN na teškim klasama, sugeri šući da ImageNet reprezentacije sadrže fine teksturalne i gradijentne obrasce korisne za distinkciju spektralno sličnih klasa.

F. Pretnje validnosti

Interna validnost: Sva poređenja sprovedena su sa jednim *seed*-om (vrednost 42). Varijansa između pokretanja nije merena, pa je moguće da deo razlika u performansama između modela potiče od varijanse inicijalizacije. Višestruka evaluacija sa različitim *seed*-ovima (npr. 42, 43, 44) sa prikazom srednje vrednosti i standardne devijacije preporučuje se za buduće radove.

Eksterna validnost: Rezultati su specifični za EuroSAT RGB format i rezoluciju 64×64 piksela. Prenosivost zaključaka na multispektralne Sentinel-2 snimke (13 kanala), veće rezolucije ili drugačije geografske regione nije testirana i ostaje otvoreno istraživačko pitanje.

V. ZAKLJUČAK

U ovom radu sprovedena je komparativna studija referentnog CNN, EfficientNetB0 i ResNet50 za 10-klasnu LULC klasifikaciju na skupu EuroSAT [1]. Eksperimentalni rezultati, dobijeni po strogo simetričnom protokolu sa fiksiranom stratifikovanom podelom (*seed*: 42) i pravilom zaštite od curenja informacija pri selekciji, potvrđuju sledeće zaključke:

- Modeli zasnovani na transferu znanja konzistentno nadmašuju referentni CNN: ResNet50 za +1,76 pp, EfficientNetB0 za +1,27 pp u makro F1 na test skupu.
- Dvostepeno fino podešavanje je neophodno: konfiguracija sa isključivo zamrznutom osnovom mreže (Faza 1) jasno zaostaje, dok Faza 2 donosi konzistentnih ~5 pp poboljšanja makro F1.
- Augmentacija ostaje kritična i za modele zasnovane na transferu znanja: njeno uklanjanje degradira makro F1 za 0,77–1,49 pp.
- ResNet50 postiže optimalan kompromis između tačnosti (97,88%), brzine konvergencije (14 epoha) i stabilnosti generalizacije (razlika validacioni–test F1: +0,0002 pp).

Ograničenja rada uključuju evaluaciju sa jednim *seed*-om i specifičnost za EuroSAT RGB format dimenzija 64×64. Budući rad treba da obuhvati: (a) višestruku evaluaciju sa različitim *seed*-ovima radi procene varijanse rezultata; (b) primenu na multispektralne Sentinel-2 snimke (13 kanala) radi ispitivanja doprinosa dodatnih spektralnih informacija; (c) istraživanje modernijih arhitektura poput Vision Transformer (ViT) i Swin Transformer modela; (d) analizu grešaka uz vizualizaciju gradijentnih mapa (engl. *Grad-CAM*) radi interpretabilnosti odluka modela.

LITERATURA

[1] P. Helber, B. Bischke, A. Dengel i D. Borth, „EuroSAT: A Novel Dataset and Deep Learning Benchmark for Land Use and Land Cover Classification," IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, vol. 12, no. 7, str. 2217–2226, jul 2019.

[2] M. Tan i Q. Le, „EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," u Proc. 36th International Conference on Machine Learning (ICML), Long Beach, CA, SAD, str. 6105–6114, jun 2019.

[3] K. He, X. Zhang, S. Ren i J. Sun, „Deep Residual Learning for Image Recognition," u Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, SAD, str. 770–778, jun 2016.

[4] L. Zhang, L. Zhang i B. Du, „Deep Learning for Remote Sensing Data: A Technical Tutorial on the State of the Art," IEEE Geoscience and Remote Sensing Magazine, vol. 4, no. 2, str. 22–40, jun 2016.

[5] A. Krizhevsky, I. Sutskever i G. E. Hinton, „ImageNet Classification with Deep Convolutional Neural Networks," Advances in Neural Information Processing Systems, vol. 25, str. 1097–1105, 2012.

[6] S. J. Pan i Q. Yang, „A Survey on Transfer Learning," IEEE Transactions on Knowledge and Data Engineering, vol. 22, no. 10, str. 1345–1359, oktobar 2010.

[7] K. Nogueira, O. A. B. Penatti i J. A. dos Santos, „Towards Better Exploiting Convolutional Neural Networks for Remote Sensing Scene Classification," Pattern Recognition, vol. 61, str. 539–556, januar 2017.